


• 目的と背景

- 本研究の目的は、ニューラルネットワークにおける中間表現（latent）を、入力と出力をつなぐ構造的な接点として再評価し、特に入力 x と出力 y の間のマッピング関係を明らかにすることである。通常の end-to-end 学習では、 $x \rightarrow z \rightarrow y$  の順方向のみが重視され、中間の latent は解釈の難しい特徴として扱われがちである。そこで本研究では、順方向（ $x \rightarrow z \rightarrow y$ ）に加えて逆方向（ $y \rightarrow z \rightarrow x$ ）の経路も構築し、x と y の両方から latent にマッピングできる構造を試みた。encoder・decoder に加えて inverse encoder を導入することで、latent を一方向的な通過点ではなく、両方向をつなぐ橋渡しとして捉え直す。また、逆方向の情報から decoder を学習可能かどうかを検証しつつ、最終的には latent を介して x と y の対応関係をどこまで構造的に捉えることができるかを探る。本研究の構造は **autoencoder** に類似するが、自己再構成ではなく  $x \leftrightarrow y$  間の構造的理解に重点を置いている。



アプローチ1：

- Encoder と Inverse Encoder を同時に学習し、出力が一致する latent を探索
- 得られた latent を固定し、Decoder を学習
- 最後に Encoder + Decoder を fine-tuning

アプローチ2：

- Inverse Encoder と Decoder を先に同時学習
- Inverse Encoder を固定し、Encoder を学習
- 最後に全体を fine-tuning
- 両アプローチの目的：latent の**構造的性の把握**と decoder の**解釈性向上**

| モデル            | 情報集約の方法     | 構造的特徴      |
|----------------|-------------|------------|
| ViT（Attention） | グローバルな重み付け  | クラスタリング的構造 |
| U-Net（Conv）    | ローカルな重み付け   | 局所構造重視     |
| MLP            | 全結合による情報圧縮  | 線形近似的      |
| PCA + MLP      | 基底展開 + 線形抽出 | 明示的な低次元構造  |

評価指標：

- Loss 関数：損失の大きさ
- Cos 類似度：表現の近さと方向の一致

| Model    | Type          | Loss        | CosineSimilarity |
|----------|---------------|-------------|------------------|
| MiniViT  | End-to-end    | 1136.645630 | 0.640099         |
| MiniUNet | End-to-end    | 1177.398193 | 0.623277         |
| PCAMLP   | End-to-end    | 1250.250977 | 0.593740         |
| MLP      | End-to-end    | 1172.771851 | 0.625085         |
| MiniViT  | path1_combine | 1254.539795 | 0.590444         |
| MiniUNet | path1_combine | 1215.498169 | 0.607196         |
| PCAMLP   | path1_combine | 1251.458496 | 0.592249         |
| MLP      | path1_combine | 1275.135864 | 0.583827         |
| MiniViT  | path2_combine | 1128.647095 | 0.643063         |
| MiniUNet | path2_combine | 1134.848999 | 0.640581         |
| PCAMLP   | path2_combine | 1256.227905 | 0.590112         |
| MLP      | path2_combine | 1161.623413 | 0.629732         |

理論的視点と抽象構造

- latent を、入力 x と出力 y を結ぶ「構造的な変数」として再定義することを目的とする
- 通常のニューラルネットワークでは  $x \rightarrow y$  の一方向のみを end-to-end で学習し、latent はブラックボックス的に扱われがち
- 本研究では、順方向（ $x \rightarrow z \rightarrow y$ ）と逆方向（ $y \rightarrow z \rightarrow x$ ）の両経路を設計し、双方向的な構造を構築
- $x \rightarrow y$  を「情報の圧縮」、 $y \rightarrow x$  を「情報の生成」とみなし、latent をその中間に位置づける
- x の確率分布が z を通して y に写像される過程を「測度変換（measure transformation）」として捉える
- encoder  $f(x)$  と inverse encoder  $g(y)$  を同時に学習し、両者の出力が一致する latent ( $f(x) \doteq g(y)$ ) を目指す
- decoder は得られた z をもとに出力 y を再構成し、 $g^{-1}(g(y)) \approx y$  を満たすことで自己教師ありの学習が可能
- latent を介することで x 側と y 側の処理をほぼ独立に扱え、構造の分離性と解釈性が向上
- $x \leftrightarrow y$  のマッピング関係を latent を通じた path の集合として捉え、多様な構造的変換を実現
- Flow matching:  $x_t \sim \mathcal{N}(\alpha Z, \beta^2 I) \quad u_t \sim \mathcal{N}(\alpha' Z, \beta'^2 I)$

$$f(x_t) \sim \mathcal{N}(f(\alpha Z), \nabla f(\alpha Z) \beta^2 I \nabla f(\alpha Z)^\top)$$

🔧 実装と設計

- 使用ライブラリ：jaxtyping（型安全）、einops（テンソル操作）、ABC（柔軟なモジュール設計）
- Optimizer：Adam（lr = 1e-3）、Seed：42、初期化：Truncated normal
- Encoder 出力：Float[Array, "batch seq dim"]（seq = h × w）
- Decoder 出力：Float[Array, "batch channel height width"]
- 条件付け：
  - 時間埋め込み：Fourier Encoder
  - ラベル埋め込み：Embedding層
  - t + label を latent に加算（Context構造）
- モデル構成：
  - ViT/U-Net の縮小版Encoder、MLP、PCA+MLP を使用
  - 線形層はカスタム Dense クラスで統一

• 主な発見：

- Encoder・Decoder・Inverse Encoder を同時学習すると **loss 低下が不十分**
- 学習順序が性能に大きく影響**

- 「Latent → Decoder」の順は、「Inverse Encoder + Decoder → Encoder」より loss が大きくなりがち（特に ViT で顕著）

- Decoder を先に学習し → その後 Encoder を学習する構成**では、**End-to-End 学習よりも loss が低くなる傾向**

- Decoder の初期 loss が低いほど、後続の Encoder 学習は困難になる傾向

→ ただし **全体の平均 loss は End-to-End より低下**

- ViT・MLP の一部では t検定・KS検定で **有意差なし（fail to reject）**  
→ 逆向き経路による学習でも End-to-End に匹敵、またはそれ以上の表現が可能

- Decoder の質が最重要：**

- 小さな latent loss より、**表現を活かせる Decoder 設計が鍵**
- Self-supervised learning では **Transformer 系（ViT 等）が最も有効**